


Physics-*un*informed machine learning



统计物理青年通讯

April 2026



SANTA FE
INSTITUTE

章元肇

y-zhang.com

How do we study a complex system?

Lots of physics, small data



How do we study a complex system?

$$\frac{d\phi_k}{dt} = \omega_k + \frac{K}{N} \sum_{j=1}^N \sin(\phi_j - \phi_k)$$

Lots of physics, small data



Start with physics

Coupled oscillators

Zhang et al., PRX 2020

Zhang & Strogatz, Nat. Commun. 2021

Zhang & Motter, PRL 2021

Stability/bifurcation analysis

Zhang & Motter, SIAM Rev. 2020

Zhang, Lucas, Battiston, Nat. Commun. 2023

Global analysis

Zhang & Strogatz, PRL 2021

Zhang et al., Sci. Adv. 2024

Groisman, De Vita, Bonder, Zhang, PRE 2025

Physics



Lots of physics, small data

No physics, big data

Data




Physics

Lots of physics, small data

No physics, big data

Zhang et al., PNAS 2021
Huang, Zhang, and Braun, Chaos 2023




No physics, small data

Complex systems

Data


生物钟是一个很好的例子， small data small physics

Extrapolating to new initial conditions



Part I

Extrapolating to new systems



Part II

和耦合。从非线性耦合，这些耦合器就会自动同步。这个实验验证了同步现象，也暗示了他研究的复杂系统同步问题。

(注：根据提供的信息，已调整人称代词使用)

学霸笔记7分钟前

这里讲的是研究复杂系统的两种不同思路。当我们对系统的物理原理很了解但缺乏观测数据，可以从基本原理出发，先建立控制方程 (governing equation)，再研究这些方程描述的动力行为。

以耦合振子 (coupled oscillator) 系统为例，我们可以用多种分析方法：1) 作为耦合振子系统来分析；2) 进行线性稳定性分析，判断同步状态的稳定性；3) 全局分析，研究整个相空间 (phase space) 的行为。这些方法的选择取决于我们对系统的了解程度。

学霸笔记6分钟前

章元肇提到，从观测数据中提取最大信息量是研究的关键。他建议从现有数据出发，主要有两种思路：一是尝试逆向推导底层动力学方程（虽然这通常很有挑战性），二是用神经网络近似模拟系统动态，建立替代模型 (surrogate model)。这样即使没有精确的物理方程，也能进行预测和控制。

他特别说明，之前展示的简化一维状态其实是个"善意谎言"——实际研究中我们往往需要在完全了解物理机制的情况下开展工作。这里隐含了一个重要方法论：当理论建模困难时，数据驱动的方法能提供有效补充。

学霸笔记4分钟前


章元肇提到一个很典型的研究困境：物理机制不明确，同时数据又不足，这就像被卡在左下的尴尬区域。他举了个生动的例子——生物钟系统：虽然由2万个神经元共同运作，但单个神经元根本没法独立决定作息时间。关键在于这些神经元会通过同步协作（就像团队喊口号统一步调），最终才能形成有规律的生物节律。

(核心难点在于：复杂系统往往既难用物理定律解释，又缺乏足够数据支撑建模，生物钟的例子完美展现了这种"两头难"的特性)

章元肇的讲座主要分为两部分：第一部分探讨如何从已知初始条件的训练数据出发，外推预测从未见过的初始条件。这就像用熟悉的拼图块去推测全新图案的可能性。第二部分更深入，研究当训练数据和预测数据来自不同系统时的表现，相当于用自行车运动数据来预测汽车行为，挑战性更大。他特别鼓励听众随时提问互动，不用等到最后。



学霸笔记刚刚

章元肇在讲解机器学习模型时提到，研究人员开发了多种从数据中学习动力学模型的方法。这些模型可以排列在一个连续谱系（spectrum）上：一端是加入大量物理对称性和守恒定律约束的physics-informed模型（物理知识导向型），这类模型虽然需要较少数据量，但具有更强的外推预测能力；另一端则是更灵活的physics-uninformed模型（如普通神经网络），适用于对底层物理规律认知不足的场景。关键点在于：物理知识约束能显著提升模型在训练数据未覆盖情况下的泛化能力，但实际应用中常因物理认知局限而无法采用这种强约束方式。





Root finding algorithm

Basins of attraction





Protein folding

Neural networks



Hopfield networks





Cell differentiation



Training Data

Testing Data





Xu, et. al. ICLR 2021.

他特别说明，之前展示的时间化一维状态其实是个“善息谎言”——实际研究中我们往往需要在不完全了解物理机制的情况下开展工作。这里隐含了一个重要方法论：当理论建模困难时，数据驱动的方法能提供有效补充。

学霸笔记8分钟前

章元肇提到一个很典型的研究困境：物理机制不明确，同时数据又不足，这就像被卡在左下角的尴尬区域。他举了个生动的例子——生物钟系统：虽然由2万个神经元共同运作，但单个神经元根本没法独立决定作息时间。关键在于这些神经元会通过同步协作（就像团队喊口号统一步调），最终才能形成有规律的生物节律。

（核心难点在于：复杂系统往往既难用物理定律解释，又缺乏足够数据支撑建模，生物钟的例子完美展现了这种“两头难”的特性）

学霸笔记7分钟前

章元肇提到，目前生物钟研究面临两大挑战：一是数据局限性——我们拥有大量正常运作（functional）的生物钟数据，但缺乏“时差状态”等异常情况的数据。比如从上海飞到纽约时，生物钟被打乱（disrupted circadian clock），这时需要知道“下一顿饭什么时候吃”能最快调整时差，但这类关键数据却很稀缺。

二是理论理解的不足，尤其大脑生物钟机制更为复杂。他特别想探讨的是：在物理认知有限且数据匮乏的双重限制下，我们还能做出哪些有价值的研究突破？这就像试图修理一台精密仪器，既没有完整说明书，又缺少关键零件时的创新思路。

Reservoir computing: flexible, physics-uninformed ML

Maass et al., Neural Comput. 2002

Jaeger and Haas, Science 2004


Pathak et al., PRL 2006

Grigoryeva and Ortega, Neural Netw. 2006

Zhang and Cornelius, PRR 2007

Yan et al., Nat. Commun. 2009


Zhang et al., Chaos 2010





Norton, **Zhang**, Girvan, Chaos 2025.

Fixed-point
attractors



Duffing system

$$\begin{aligned}\dot{x} &= y \\ \dot{y} &= ay - bx - cx^3\end{aligned}$$



Michelle Girvan



Declan Norton

物理约束在神经网络中的重要性：章元肇提到，如果神经网络不加物理约束，模型会过于灵活，缺乏好的归纳偏置（inductive bias）。这意味着它在训练数据范围内可能拟合得很好，但一旦超出这个范围，预测就会变得不可靠，因为它没有周期性函数那样的内在规律性。

在数据驱动的动态系统建模中，这个问题同样存在。他举了个简单系统的例子：左右各有一个固定点吸引子

（fixpoint attractor）。如果没有数据引导，神经网络只能“瞎猜”，无法给出靠谱的预测。

简单说，没约束的神经网络就像没学过物理的人乱猜物体运动轨迹——训练数据范围内还行，超出范围就崩了。

学霸笔记9分钟前

章元肇提到，最先进的机器学习模型对见过的轨迹（红色部分）预测效果很好，但对未见过的轨迹预测表现很差，连基本的固定点吸引子都无法捕捉，更不用说复杂的瞬态和动态行为。这说明在没有物理信息指导的情况下，神经网络很难对未见过的相空间或动力学进行外推。

他和同事讨论时，同事建议尝试储层计算（reservoir computing），但他认为储层计算同样缺乏物理信息的融入。于是他们打了个赌，想验证储层计算是否能实现这种外推能力。储层计算的结构大致分为三层：输入层（接收训练信号或轨迹）、储层（非线性动态系统）和输出层（线性变换）。

学霸笔记7分钟前


这里讲的是一个储备池计算（Reservoir Computing）的核心思想。第一层会随机生成大量神经元的连接，形成一个高




$$\ddot{x} = -\omega_0^2 x - a\dot{x} + \sum_{i=1}^3 \frac{\tilde{x}_i - x}{D(\tilde{x}_i, \tilde{y}_i)^3},$$

$$\ddot{y} = -\omega_0^2 y - a\dot{y} + \sum_{i=1}^3 \frac{\tilde{y}_i - y}{D(\tilde{x}_i, \tilde{y}_i)^3},$$


$$D(\tilde{x}, \tilde{y}) = \sqrt{(\tilde{x} - x)^2 + (\tilde{y} - y)^2 + h^2}$$





Pros

- Easy to train
- Flexible
- Theoretically grounded




Pros

- Easy to train
- Flexible
- Theoretically grounded
- Extrapolate from limited data without physics

Cons

- Costed me an expensive dinner




Pros

- Easy to train
- Flexible
- Theoretically grounded
- Extrapolate from limited data without physics

Cons


- Costed me an expensive dinner
- System specific
- Data requirement
- Hyperparameter tuning
- Hard to scale

Extrapolating to new initial conditions




Part I

Extrapolating to new systems



Part II



forecast the dynamics of a new system solely based on a short trajectory?

Data from Lorenz



Train
→
(fit the flow)

Classical
models

Forecast
→



Prediction for Lorenz

Time series data from
diverse domains
(not including Lorenz)



Pre-train
→
(learn general
forecasting
strategies)

Foundation
models

Forecast
→
(zero shot)




Prediction for Lorenz

Works out of the box for *new* systems:



Partially
observed



Lorenz system

$$\frac{dx}{dt} = \sigma(y - x)$$

$$\frac{dy}{dt} = x(\rho - z) - y$$

$$\frac{dz}{dt} = xy - \beta z$$


William Gilpin



Zhang and Gilpin, ICLR 2
Zhang and Gilpin. ICLR 2



Partially
observed




Good short-term prediction
+
Faithful reconstruction of
global attractor properties

Lorenz system

$$\begin{aligned}\frac{dx}{dt} &= \sigma(y - x) \\ \frac{dy}{dt} &= x(\rho - z) - y \\ \frac{dz}{dt} &= xy - \beta z\end{aligned}$$

Zero-shot prediction
Ground Truth




William Gilpin



Zhang and Gilpin, ICLR 2025
Zhang and Gilpin, ICLR 2026



**What are foundation models
doing under the hood?**



数据要求为凸，而参数空间到数据点分布的数据点可能有效训练。最关键的是，超参数选择对性能影响极大，比如随机连接的参数若没调好，效果会大打折扣。这恰恰暴露了储备计算方法的瓶颈所在。

学霸笔记21:35

Ridge regression在小规模系统（几百到1000个节点）中效率极高，几秒就能得出解。但它需要计算矩阵逆运算（matrix inverse），而矩阵逆的复杂度随系统规模急剧上升，导致无法处理十亿级节点的系统。

关于训练单一初始状态却能泛化到其他状态的现象，章元肇提到可能源于simplicity bias（简单性偏好），即系统倾向于学习底层规律而非随机细节，但具体机制仍在研究中。

Ruicheng猜测随机性（randomness）可能帮助模型间接捕捉其他初始状态的特征。

学霸笔记21:37


章元肇在讲解时提到，他们测试的系统是基于简单ODE生成的，这会导致两种偏差叠加。为了更精确地分析，需要将reservoir状态映射到kernel function，通过kernel function隐含的非线性特征来研究其与ground truth方程中非线性项的匹配程度。

当陈笑闻问到对称性对结果的影响时，章元肇表示这正是他想讨论的问题，但暂时中断了讲解。这里的关键是通过kernel方法将高维reservoir状态转化为可分析的非线性特征，这种方法能帮助我们更深入地理解系统的内在特性。


学霸笔记21:39

章元肇在讨论对称性破缺对系统行为的影响。他举了

What are foundation models doing under the hood?




Foundation models often make predictions by **context parroting**



A simple strategy inspired by foundation models in turn beats all of them!

Context parrotting should serve as a naïve baseline



Compu
样本预
这部分
程非常
活性很
近似

虽然这
个待解
目前有
到的逆
好的特

学霸笔记

最小化
能从有
也指出
吃饭)
特异性
来。

数据要
效训练
机连接
备计算

学霸笔记

Ridge r
率极高
(matr
, 导致

关于训
第 提到
向于学

Zhang

正在讲话:

批注

比如某些昂贵的物理实验或生物观测。

学霸笔记21:47

章元肇提到，基于短轨迹预测的能力在流体力学、神经科学和天气预报等领域都有广泛应用。这解释了为什么现在很多人都在研究基础模型（foundation model）——这种模型能根据从未见过的短时间序列，预测任何系统的未来状态。

他把这种基础模型和经典模型做了对比。以洛伦兹系统为例，经典模型（比如储备计算）需要从洛伦兹方程生成训练轨迹，然后调整权重来拟合底层的流映射或向量场。而基础模型的目标是更通用，不需要针对特定系统做专门训练。


学霸笔记21:49

基础模型（foundation model）的强大之处在于它能用多样化的训练数据（比如天气、金融等不同时间序列）来学习通用的预测策略，而不需要针对特定系统（如洛伦兹系统）专门训练。这种模型开箱即用，对新系统无需重新训练或调参，推理阶段也只需少量数据且速度较快。

举个例子，就像学会通用烹饪方法后，不用看菜谱也能炒新菜。章元肇提到的Chronos模型就是这类工具，能直接对陌生数据做零样本预测（zero-shot forecast），省时省力。

学霸笔记21:51

这里讲的是一个部分可观测系统的预测难题。章元肇提到，虽然底层系统实际上是三维的（X、Y、Z相互影响），但我们只能观测到X这一个变量。这种情况下做预测 notoriously



本次讲座介绍了Reservoir Computing和Foundation Model在复杂系统建模中的应用，重点探讨了其在数据有限、物理机制未知情况下的泛化能力和预测机制。

知识点梳理

1. 复杂系统建模的挑战与两种范式

•挑战: 当面对既缺乏深入物理理解又难以获取充足观测数据的复杂系统（如生物钟）时，传统的建模方法面临巨大困难。

•两种范式:

- Physics-informed modeling: 基于已知的物理规律构建模型，数据需求少，但泛化能力有限。
- Data-driven modeling: 仅从数据中学习动力学，灵活性高，但缺乏物理约束，导致在训练数据之外的区域（extrapolation）预测效果差。

2. Reservoir Computing的泛化能力

- 原理: 该方法由一个固定的、随机连接的高维Reservoir层和一个待训练的线性输出层构成。Reservoir层负责捕捉系统的动态特征，通过求解一个线性回归问题来训练输出层。
- 优势: 在没有显式物理约束的情况下，Reservoir Computing表现出惊人的泛化能力，能够成功预测训练时未曾见过的初始条件，甚至能捕捉到系统中其他吸引盆地（basin of attraction）的整体结构。
- 机制猜想: 泛化能力可能源于其内在的“简约性偏置”（simplicity bias），即在多个可能的解中，倾向于选择最简单的解。此外，Reservoir层的随机性也可能有助于捕捉系统的复杂动态。
- 局限: 方法对超参数（如Reservoir连接权重）敏感，需要进行调优；且模型是针对特定系统独立训练的，难以迁移应用。

3. Foundation Model的预测能力

- 原理: Foundation Model（如Chronos）通过在大量多样化的时序数据上进行训练，学习一种通用的预测策略，从而实现“零样本”（zero-shot）预测。
- 优势: 在面对全新的、从未见过的系统时，仅凭一段短暂的观测轨迹，Foundation Model仍能进行短期预测，并重建出系统的全局吸引子几何结构，性能甚至优于为每个系统单独训练的经典模型。
- 机制猜想: 其底层机制可能非常基础，例如通过识别并复制输入序列中的重复模式（motif）来进行预测。研究发现，这种模式匹配机制可以很好地解释Foundation Model的预测误差随上下文长度呈现的幂律衰减规律。

课后作业

本次讲座未布置课后作业。



在于：1) 通过分量预测再组合的方式处理多维系统；2) 借鉴了LLM的注意力机制架构。这种跨领域的架构迁移展现了

- 原理: Foundation Model (如Chronos) 通过在大量多样化的时序数据上进行训练, 学习一种通用的预测策略, 从而实现“零样本”(zero-shot) 预测。
- 优势: 在面对全新的、从未见过的系统时, 仅凭一段短暂的观测轨迹, Foundation Model仍能进行短期预测, 并重建出系统的全局吸引子几何结构, 性能甚至优于为每个系统单独训练的经典模型。
- 机制猜想: 其底层机制可能非常基础, 例如通过识别并复制输入序列中的重复模式 (motif) 来进行预测。研究发现, 这种模式匹配机制可以很好地解释Foundation Model的预测误差随上下文长度呈现的幂律衰减规律。

课后作业

本次讲座未布置课后作业。

新采。章元肇提到的Chronos模型就是这类工具，能直接对陌生数据做零样本预测（zero-shot forecast），省时省力。

学霸笔记21:51

这里讲的是一个部分可观测系统的预测难题。章元肇提到，虽然底层系统实际上是三维的（X、Y、Z相互影响），但我们只能观测到X这一个变量。这种情况下做预测 notoriously difficult（非常困难），特别是当基础模型完全不了解底层方程时。

但令人惊讶的是，这个基础模型不仅短期预测准确，还能在预测出现偏差后，长期仍能捕捉到系统的吸引子结构（attractor capture）。也就是说，模型仅凭短短的一段轨迹数据，就能重建整个系统的全局几何特征。这确实很反直觉——毕竟模型对这个混沌系统完全陌生。

他们用包含100多种混沌系统的数据集测试了这个基础模型的表现。这个案例展示了即使在不了解系统机理、数据有限的情况下，现代模型仍可能做出惊人的预测。

学霸笔记21:53

基础模型的预测准确率随着模型规模增大而提升，最大规模的基础模型表现已经媲美传统方法。这里有个关键区别：基础模型是单一模型处理所有混沌系统，而传统方法是每个系统单独训练模型。这种"以一敌百"还能打平手的表现确实令人惊喜。

不过作为物理学者，我们更关心的是基础模型背后的预测机制。就像他展示的轨迹图，模型究竟捕捉到了什么规律？这值得深入探讨。传统方法虽然效果相当，但每个模型都

Physics-informed Modeling: 基于已知的物理规律建立模型, 数据需求少, 但泛化能力 (extrapolation) 可能受限。
Data-driven Modeling: 仅从观测数据中学习系统动力学, 灵活性高, 但泛化能力同样面临挑战。

2. Reservoir Computing的泛化能力

核心优势: 无需显式引入物理约束, 仅通过一个随机连接的Reservoir层和一个线性输出层即可实现强大的泛化能力, 能够成功预测训练时未曾见过的初始条件 (属于不同吸引盆地) 下的系统行为。

机制猜想: 其泛化能力可能源于ridge regression求解时倾向于寻找“最简单” (即范数最小) 的解, 从而保留了对未知动力学的鲁棒性。

局限性: 该方法是针对特定系统定制的 (system-specific), 需要针对每个新系统进行超参数 (如Reservoir连接权重) 的搜索和调整, 且难以扩展至大规模网络。

3. Foundation Model的跨系统预测能力

核心优势: 通过在大量多样化的时序数据上进行预训练, Foundation Model (如Chronos) 能够实现“零样本” (zero-shot) 预测, 即仅凭一个全新的、极短的轨迹片段, 就能对